

## Proiect Statistică

Chirobocea Mihail-Bogdan 312

Costea Răzvan-George 311

Marin Mircea-Mihai 312

Popa Mihai-Cristian 311

Lider echipă: Chirobocea Mihail-Bogdan

## I. Inegalitatea Berry-Essen

1. Am transmis prin parametru pdf-ul / pmf-ul variabilei aleatoare X. Au fost folosite formulele pentru medie și varianță:

$$E(X) = \int_{-\infty}^{\infty} xf(x)dx \quad / \quad \sum_{i=0}^n x_i p_i$$
$$\text{Var}(X) = E(X^2) - E(X)^2$$

```
3 #1
4
5 # Expected value for continuous random variable
6 E_c <- function(pdf){
7   x1 <- runif(10^6)
8   x_inf <- (1-x1)/x1
9   f <- function(x) x * pdf(x) * 1/x1^2
10  return(mean(f(x_inf)))
11 }
12
13 # Variance for continuous random variable
14 Var_c <- function(pdf){
15   x1 <- runif(10^6)
16   x_inf <- (1-x1)/x1
17   f <- function(x) x**2 * pdf(x) * 1/x1^2
18   return(mean(f(x_inf)) - E_c(pdf)**2)
19 }
20
21 # Expected value for discrete random variable
22 E_d <- function(pmf) {
23   x <- seq(0, 10^2, 1)
24   return(sum(x*pmf(x)))
25 }
26
27 # Variance for discrete random variable
28 Var_d <- function(pmf) {
29   x <- seq(0, 10^2, 1)
30   prob <- pmf(x)
31   return(sum(x**2*prob) - sum(x*prob)**2)
32 }
33
```

În cazul discret, probabilitățile sunt calculate folosind funcția de masa, i.e. pmf. În cazul continuu integrala este calculată folosind metoda Monte Carlo.

2. Funcția primește ca parametru o variabilă aleatoare X și returnează rezultatul cerut.

```
34 #2
35 mom_3 <- function(X){
36   return(mean(abs(X - mean(X))**3))
37 }
38
```

3. Am scris o funcție care calculează marginea Berry-Essen care primește ca parametru variabila aleatoare  $X_1$  și volumul eșantionului  $n$ . Apoi am construit un dataframe care conține primele 2 coloane, i.e. distribuția și volumul pentru care va fi calculată marginea. Pentru fiecare volum  $n$  am generat  $10^6$  numere din fiecare distribuție și am calculat marginea. Aceste rezultate sunt puse într-un vector, iar acest vector este adăugat ca și coloană la dataframe.

```

38
39 #3
40 BE_Margin <- function(X_1, n){
41   sigma = sqrt(mean(X_1**2) - mean(X_1)**2)
42   return(33/4 * (mom_3(X_1)) / (sqrt(n) * sigma**3))
43 }
44
45 names = c('Binomial', 'Geometric', 'Poisson', 'Uniform', 'Exponential', 'Gamma', 'Beta')
46 volumes = c(30, 100, 1000)
47
48 # Create a dataframe with Distribution and Volume columns
49 BE_Margins <- data.frame(
50   'Distribution' = c(c(names, names), names),
51   'Volume' = sort(c(c(c(c(c(volumes, volumes), volumes), volumes), volumes), volumes), volumes))
52 )
53
54 margins <- c()
55
56 for(n in volumes){
57   # Discrete rv
58   X_1_bin = rbinom(10^6, 3, 0.4)
59   X_1_geom = rgeom(10^6, 0.3)
60   X_1_pois = rpois(10^6, 10)
61   X_1_unif = sample(1:20, 10^6, replace=T)
62
63   # Continuous rv
64   X_1_exp = rexp(10^6, 3)
65   X_1_gamma = rgamma(10^6, 9, 0.5)
66   X_1_beta = rbeta(10^6, 2, 2)
67
68   # Calculate the B-E margins for every given distribution
69   margins <- c(margins, BE_Margin(X_1_bin, n))
70   margins <- c(margins, BE_Margin(X_1_geom, n))
71   margins <- c(margins, BE_Margin(X_1_pois, n))
72   margins <- c(margins, BE_Margin(X_1_unif, n))
73   margins <- c(margins, BE_Margin(X_1_exp, n))
74   margins <- c(margins, BE_Margin(X_1_gamma, n))
75   margins <- c(margins, BE_Margin(X_1_beta, n))
76
77 }
78
79 # Append the Margin column to dataframe
80 BE_Margins$Margin = margins
81
82 # Print
83 BE_Margins
84

```

	Distribution	Volume	Margin
1	Binomial	30	2.2131096
2	Geometric	30	3.6616273
3	Poisson	30	2.4235634
4	Uniform	30	1.9543812
5	Exponential	30	3.6182861
6	Gamma	30	2.5472591
7	Beta	30	2.1057724
8	Binomial	100	1.2110884
9	Geometric	100	2.0002072
10	Poisson	100	1.3262601
11	Uniform	100	1.0703577
12	Exponential	100	2.0032390
13	Gamma	100	1.3992403
14	Beta	100	1.1530103
15	Binomial	1000	0.3831067
16	Geometric	1000	0.6334175
17	Poisson	1000	0.4192049
18	Uniform	1000	0.3385089
19	Exponential	1000	0.6304585
20	Gamma	1000	0.4419005
21	Beta	1000	0.3645935

În tabel se poate observa că marginea scade cu cât volumul eșantionului crește. Deci aproximarea realizată de TLC este mai exactă dacă volumul eșantionului este mare.

Cum  $\mu < \infty \wedge \sigma < \infty \wedge E(|X_i|^3) < \infty$ , atunci se poate observa că

$$\lim_{n \rightarrow \infty} \left( \frac{33}{4} \frac{E(|X_1 - \mu|)^3}{\sqrt{(n)} \sigma^3} \right) = 0$$

4. Pentru fiecare volum  $n$  a fost construită variabila aleatoare  $Z_n$ , calculând mai întâi media de selecție  $\bar{X}$ . Funcția de repartiție a fost calculată folosind funcția din R `ecdf()`.

Intervalul ales este  $[0,1]$  care a fost construit în R folosind funcția `seq()`. Pentru fiecare punct din secvență se calculează diferența cerută care este stocată într-un vector pentru a fi plotată.

Procesul descris mai sus este repetat pentru fiecare repartiție cerută.

```

87
88 # Binomial
89 volumes <- c(30, 100, 1000)
90
91 for(n in volumes){
92   X_bar <- c()
93
94   # Init the sampling mean
95   X_1 <- rbinom(10^6, 3, 0.4)
96   X_bar <- c(X_bar, mean(X_1))
97
98   for(i in 2:n){
99     X_i <- rbinom(10^6, 3, 0.4)
100    X_bar <- c(X_bar, mean(X_i))
101  }
102
103  # Init Z_n rv
104  sigma = sqrt(mean(X_1**2) - mean(X_1)**2)
105  Z_n <- (sqrt(n) * (X_bar - mean(X_1))) / sigma
106
107  # Use ecdf() function to find the cdf of Z_n
108  cdf <- ecdf(Z_n)
109
110  # Define [0, 1] interval
111  x <- seq(0, 1, 0.001)
112  diff <- c()
113  for(t in x){
114    # Compute the difference
115    diff <- c(diff, cdf(t) - pnorm(t))
116  }
117
118  # Plot
119  plot(x, diff, main=sprintf('Binomial with %d volume', n), lwd=0.5)
120  lines(x, diff, col="red")
121 }
122

```

```

122
123 # Geometric
124 volumes <- c(30, 100, 1000)
125
126 for(n in volumes){
127   X_bar <- c()
128
129   # Init the sampling mean
130   X_1 <- rgeom(10^6, 0.3)
131   X_bar <- c(X_bar, mean(X_1))
132
133   for(i in 2:n){
134     X_i <- rgeom(10^6, 0.3)
135     X_bar <- c(X_bar, mean(X_i))
136   }
137
138   # Init Z_n rv
139   sigma = sqrt(mean(X_1**2) - mean(X_1)**2)
140   Z_n <- (sqrt(n) * (X_bar - mean(X_1))) / sigma
141
142   # Use ecdf() function to find the cdf of Z_n
143   cdf <- ecdf(Z_n)
144
145   # Define [0, 1] interval
146   x <- seq(0, 1, 0.001)
147   diff <- c()
148   for(t in x){
149     # Compute the difference
150     diff <- c(diff, cdf(t) - pnorm(t))
151   }
152
153   # Plot
154   plot(x, diff, main=sprintf('Geometric with %d volume', n), lwd=0.5)
155   lines(x, diff, col="red")
156 }
157

```

```

158 # Poisson
159 volumes <- c(30, 100, 1000)
160
161 for(n in volumes){
162   X_bar <- c()
163
164   # Init the sampling mean
165   X_1 <- rpois(10^6, 10)
166   X_bar <- c(X_bar, mean(X_1))
167
168   for(i in 2:n){
169     X_i <- rpois(10^6, 10)
170     X_bar <- c(X_bar, mean(X_i))
171   }
172
173   # Init Z_n rv
174   sigma = sqrt(mean(X_1**2) - mean(X_1)**2)
175   Z_n <- (sqrt(n) * (X_bar - mean(X_1))) / sigma
176
177   # Use ecdf() function to find the cdf of Z_n
178   cdf <- ecdf(Z_n)
179
180   # Define [0, 1] interval
181   x <- seq(0, 1, 0.001)
182   diff <- c()
183   for(t in x){
184     # Compute the difference
185     diff <- c(diff, cdf(t) - pnorm(t))
186   }
187
188   # Plot
189   plot(x, diff, main=sprintf('Poisson with %d volume', n), lwd=0.5)
190   lines(x, diff, col="red")
191 }
192

```

```

192
193 # Discrete Uniform
194 volumes <- c(30, 100, 1000)
195
196 for(n in volumes){
197   X_bar <- c()
198
199   # Init the sampling mean
200   X_1 <- sample(1:20, 10^6, replace = T)
201   X_bar <- c(X_bar, mean(X_1))
202
203   for(i in 2:n){
204     X_i <- sample(1:20, 10^6, replace = T)
205     X_bar <- c(X_bar, mean(X_i))
206   }
207
208   # Init Z_n rv
209   sigma = sqrt(mean(X_1**2) - mean(X_1)**2)
210   Z_n <- (sqrt(n) * (X_bar - mean(X_1))) / sigma
211
212   # Use ecdf() function to find the cdf of Z_n
213   cdf <- ecdf(Z_n)
214
215   # Define [0, 1] interval
216   x <- seq(0, 1, 0.001)
217   diff <- c()
218   for(t in x){
219     # Compute the difference
220     diff <- c(diff, cdf(t) - pnorm(t))
221   }
222
223   # Plot
224   plot(x, diff, main=sprintf('Discrete Uniform with %d volume', n), lwd=0.5)
225   lines(x, diff, col="red")
226 }
227

```

```

228 # Exponential
229 volumes <- c(30, 100, 1000)
230
231 for(n in volumes){
232   X_bar <- c()
233
234   # Init the sampling mean
235   X_1 <- rexp(10^6, 3)
236   X_bar <- c(X_bar, mean(X_1))
237
238   for(i in 2:n){
239     X_i <- rexp(10^6, 3)
240     X_bar <- c(X_bar, mean(X_i))
241   }
242
243   # Init Z_n rv
244   sigma = sqrt(mean(X_1**2) - mean(X_1)**2)
245   Z_n <- (sqrt(n) * (X_bar - mean(X_1))) / sigma
246
247   # Use ecdf() function to find the cdf of Z_n
248   cdf <- ecdf(Z_n)
249
250   # Define [0, 1] interval
251   x <- seq(0, 1, 0.001)
252   diff <- c()
253   for(t in x){
254     # Compute the difference
255     diff <- c(diff, cdf(t) - pnorm(t))
256   }
257
258   # Plot
259   plot(x, diff, main=sprintf('Exponential Uniform with %d volume', n), lwd=0.5)
260   lines(x, diff, col="red")
261 }
262

```

```

262 # Gamma
263 volumes <- c(30, 100, 1000)
264
265 for(n in volumes){
266   X_bar <- c()
267
268   # Init the sampling mean
269   X_1 <- rgamma(10^6, 9, 0.5)
270   X_bar <- c(X_bar, mean(X_1))
271
272   for(i in 2:n){
273     X_i <- rgamma(10^6, 9, 0.5)
274     X_bar <- c(X_bar, mean(X_i))
275   }
276
277   # Init Z_n rv
278   sigma = sqrt(mean(X_1**2) - mean(X_1)**2)
279   Z_n <- (sqrt(n) * (X_bar - mean(X_1))) / sigma
280
281   # Use ecdf() function to find the cdf of Z_n
282   cdf <- ecdf(Z_n)
283
284   # Define [0, 1] interval
285   x <- seq(0, 1, 0.001)
286   diff <- c()
287   for(t in x){
288     # Compute the difference
289     diff <- c(diff, cdf(t) - pnorm(t))
290   }
291
292   # Plot
293   plot(x, diff, main=sprintf('Gamma Uniform with %d volume', n), lwd=0.5)
294   lines(x, diff, col="red")
295 }
296
297

```


```

297 # Beta
298 volumes <- c(30, 100, 1000)
299
300 for(n in volumes){
301   X_bar <- c()
302
303   # Init the sampling mean
304   X_1 <- rbeta(10^6, 2, 2)
305   X_bar <- c(X_bar, mean(X_1))
306
307   for(i in 2:n){
308     X_i <- rbeta(10^6, 2, 2)
309     X_bar <- c(X_bar, mean(X_i))
310   }
311
312   # Init Z_n rv
313   sigma = sqrt(mean(X_1**2) - mean(X_1)**2)
314   Z_n <- (sqrt(n) * (X_bar - mean(X_1))) / sigma
315
316   # Use ecdf() function to find the cdf of Z_n
317   cdf <- ecdf(Z_n)
318
319   # Define [0, 1] interval
320   x <- seq(0, 1, 0.001)
321   diff <- c()
322   for(t in x){
323     # Compute the difference
324     diff <- c(diff, cdf(t) - pnorm(t))
325   }
326
327   # Plot
328   plot(x, diff, main=sprintf('Beta Uniform with %d volume', n), lwd=0.5)
329   lines(x, diff, col="red")
330 }
331
332


```

Mai jos se pot analiza graficele pentru fiecare repartiție:


Binomial with 30 volume




Binomial with 100 volume




Binomial with 1000 volume




Geometric with 30 volume




Geometric with 100 volume




Geometric with 1000 volume




Poisson with 30 volume




Poisson with 100 volume




Poisson with 1000 volume




Discrete Uniform with 30 volume




Discrete Uniform with 100 volume




Discrete Uniform with 1000 volume




Exponential Uniform with 30 volume




Exponential Uniform with 100 volume




Exponential Uniform with 1000 volume




Gamma Uniform with 30 volume



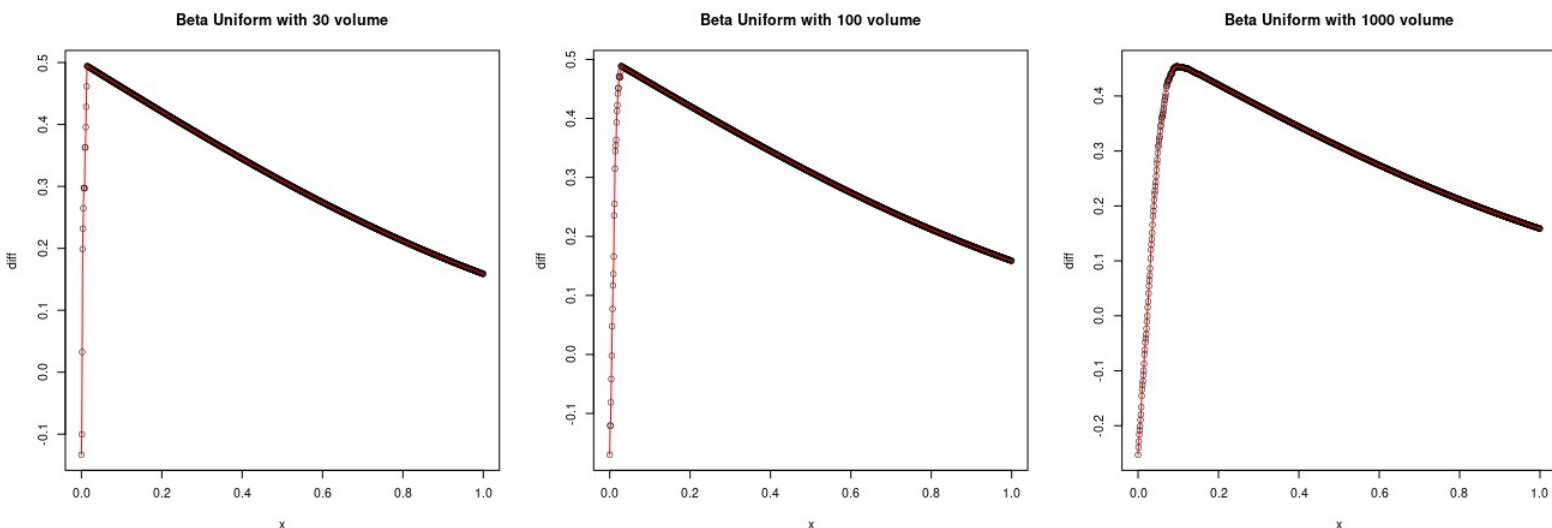
Gamma Uniform with 100 volume



Gamma Uniform with 1000 volume







5. Știind pdf-ul, respectiv pmf-ul, puntem calcula funcția de repartiție pentru a simula variabila aleatoare folosind metoda inversă. Am scris o funcție pentru cazul discret și una pentru cazul continuu. Fiecare dintre acestea folosește funcțiile scire la punctul 1.

```

335 # Compute B-E margin for continuous rv
336 Margin_c <- function(X_1, n, pdf){
337   miu <- E_c(pdf)
338   sigma <- sqrt(Var_c(pdf))
339   return(33/4 * mean(abs(X_1 - miu)**3) / (sqrt(n) * sigma**3))
340 }
341
342 # Compute B-E margin for discrete rv
343 Margin_d <- function(X_1, n, pmf){
344   miu <- E_d(pmf)
345   sigma <- sqrt(Var_d(pmf))
346   return(33/4 * mean(abs(X_1 - miu)**3) / (sqrt(n) * sigma**3))
347 }
348
349 pdf <- function(x){
350   3*exp(-3*x)
351 }
352
353 pmf <- function(x){
354   exp(-10)*(10^x)/(factorial(x))
355 }
356
357 generate_c <- function(){
358   # we know the pdf/pmf so we can find cdf/cmf and apply inverse method for exp(lambda=3)
359   u <- runif(10^6)
360   x <- -1/3*log(u)
361   return(x)
362 }
363
364 generate_d <- function(){
365   # we know the pdf/pmf so we can find cdf/cmf and apply inverse method for pois(lambda=10)
366   X <- c()
367   for(i in 1:10^6){
368     u <- runif(1)
369     j <- 0
370     p <- exp(-10)
371     F_x <- p
372     while(u >= F_x){
373       p <- (10*p)/(j+1)
374       F_x <- F_x + p
375       j <- j + 1
376     }
377     X[i] <- j
378   }
379   return(X)
380 }
381
382 X_1 <- generate_c()
383 Margin_c(X_1, 1000, pdf)
384
385 X_1 <- generate_d()
386 Margin_d(X_1, 1000, pmf)
387

```

Rezultatele obținute folosind media și varianța de la punctul 1 sunt foarte apropiate față de cele de la punctul 3, unde media a fost calculată folosind funcția din R mean(). Și în acest caz, are loc concluzia dată la punctul 3.



## Exercițiul 2

### 2.1.

Probabilitatea de acceptare a unei valori prin metoda respingerii este  $\frac{1}{c}$ , unde  $c$  este constanta care mărginește raportul  $\frac{f(x)}{g(x)}$ .

Pentru a putea ajunge la acel rezultat, ne întoarcem la algoritmul metodei respingerii:

1. Generez  $U$
2. Generez  $Y$
3.
  - a. Dacă  $U \leq \frac{f(Y)}{cg(Y)}$ , atunci  $X \leftarrow Y$
  - b. Altfel, înapoi la pasul 1.

Pasul de acceptare-respingere, **3**, conține probabilitatea de acceptare :

$$\begin{aligned} P('acceptare') &= P\left(U \leq \frac{f(Y)}{cg(Y)}\right) = \\ &= \int_D P\left(U \leq \frac{f(Y)}{cg(Y)} \middle| Y = y\right) g(y) dy \\ &= \int_D \frac{f(y)}{g(y)} g(y) dy = \frac{1}{c} \int_D f(y) dy = \frac{1}{c} \end{aligned}$$

pentru  $f, g$  funcții de densitate ale unor variabile aleatoare, unde  $D$  este domeniul de definiție al lui  $f$  (domeniu pe care l-am restrâns și pe  $g$ , i.e.  $g = g_D$ ).

### 2.2.

$$E\left[1_{U \leq \frac{f}{g}}\right] = P\left(U \leq \frac{f(Y)}{g(Y)}\right) = \frac{1}{c}, \text{ conform subpunctului 2.1.}$$

Pentru funcția  $f$  dată, unde nu cunoaștem constanta de normalizare, considerăm

$$f(x) = \alpha p(x); p(x) = \sin^2 x e^{-x^2 \sqrt{x}}$$

Atunci,  $f(x) \leq cg(x) \Leftrightarrow p(x) \leq \frac{c}{\alpha} g(x)$ . Notând  $\frac{c}{\alpha} := M$ ,  $p(x) \leq Mg(x)$ .

Atât pentru  $f(x)$  cât și pentru  $p(x)$  se poate aplica metoda respingerii, și din studiul celor două, putem găsi aproximări ale constantei de normalizare  $\alpha$ .

### 2.4.

Pentru a rezolva acest subpunct, am folosit cod R, aplicând principiile de la 2.2.

Începem cu definițiile din enunț

```
#Exercițiul 2, subpunctul 4

#partea ne-constantă a lui f. în alte cuvinte, f proporțional cu fb.
fb <- function(x) {
  (sin(x))^2*exp(-x^2*sqrt(x))
}

#g1,g2,g3 din enunț
g1 <- function(x) {
  (exp(-x))
}

g2 <- function(x) {
  (1/(pi)* (1/(1+x^2/4)))
}

g3 <- function(x) {
  (1/sqrt(pi/2)*exp(-x^2/2))
}

```

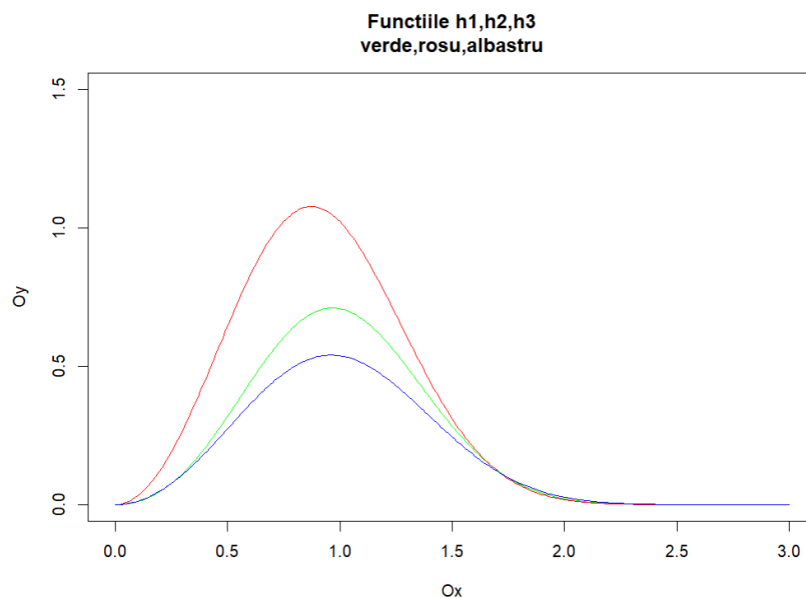
Aflăm  $c_1, c_2, c_3$  optimi (i.e.  $c_i = \max_{x \in (0, \infty)} \frac{f(x)}{g(x)}$ ) folosind funcția optimize și luând a doua poziție din lista rezultată.

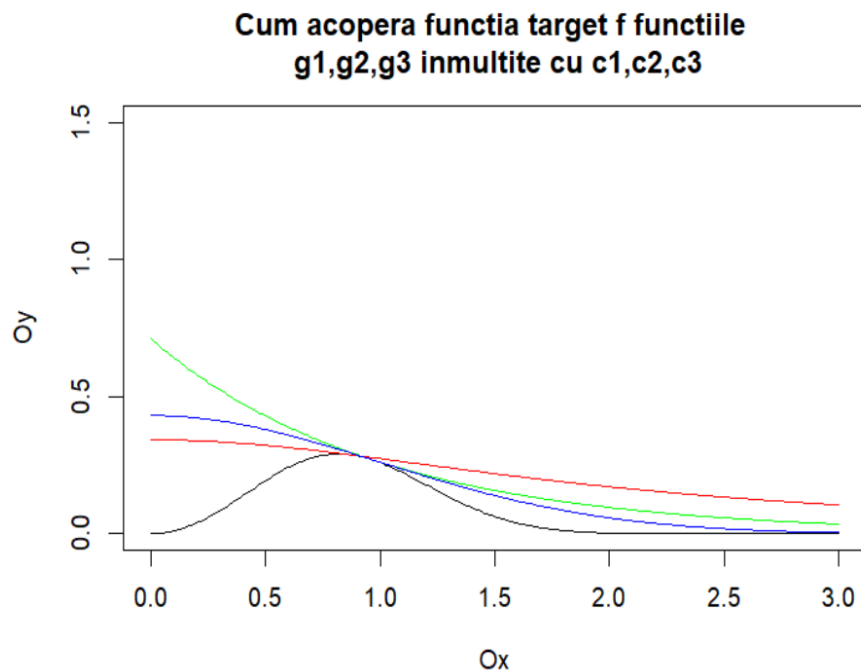
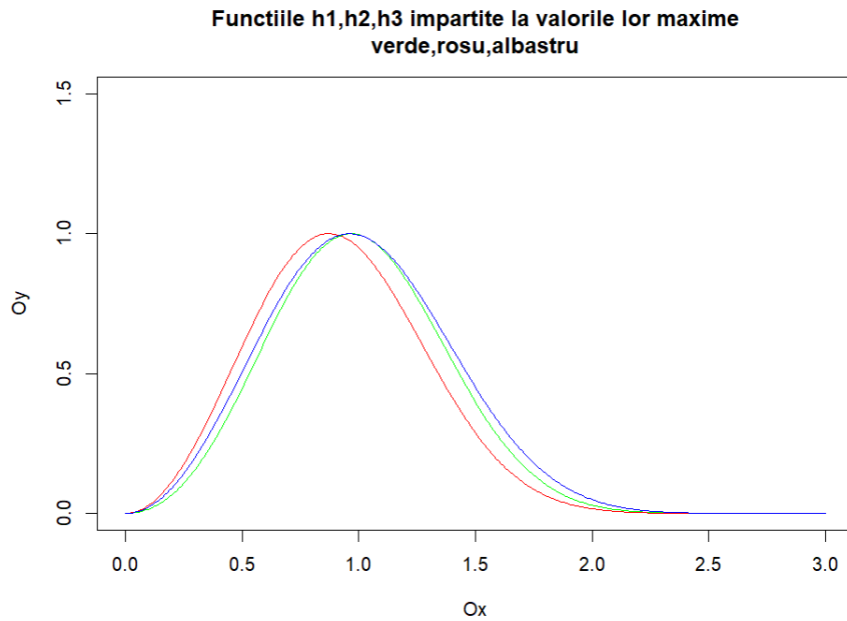
```
h1 <- function(x){
  fb(x)/g1(x)}
c1 <- optimize(h1, lower=0, upper=10, maximum = T)
h2 <- function(x){
  fb(x)/g2(x)}
c2 <- optimize(h2, lower=0, upper=10, maximum = T)
h3 <- function(x){
  fb(x)/g3(x)}
c3 <- optimize(h3, lower=0, upper=10, maximum = T)

c1 <- as.numeric((c1)[2])
c2 <- as.numeric((c2)[2])
c3 <- as.numeric((c3)[2])

```

Câteva grafice:







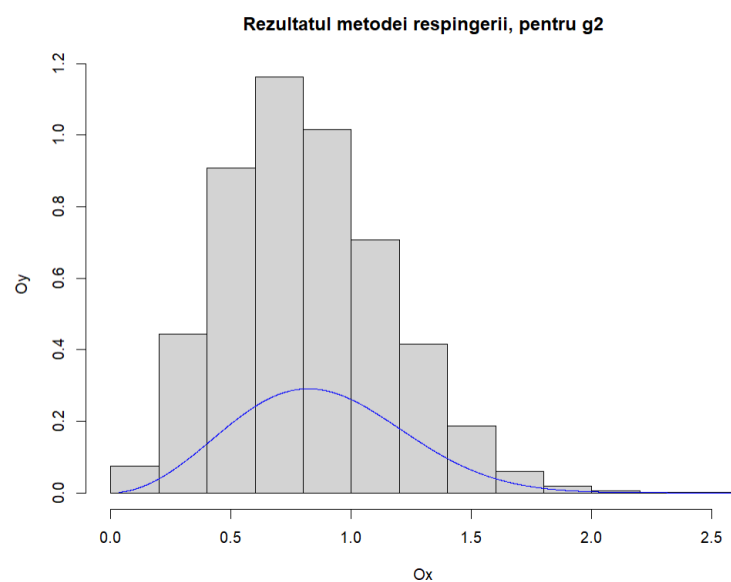
Apoi, aplicăm metoda respingerii:

```
t <- 10000

sf_1 <- function(x, n) {
  repeat {
    u <- runif(1, 0, 1)
    y <- rexp(1)
    if (u <= fb(y)/(c1*g1(y))) {
      return(y)
    }
  }
}
x1 <- sapply(1:(t), sf_1)
x1 <- seq(min(x1), max(x1), 0.001)
hist(x1, freq = F, main='Rezultatul metodei respingerii, g1', xlab='Ox', ylab='Oy')
lines(x1, fb(x1), col = "blue")
```



Pentru același cod dar cu g2, g3 în loc de g1:



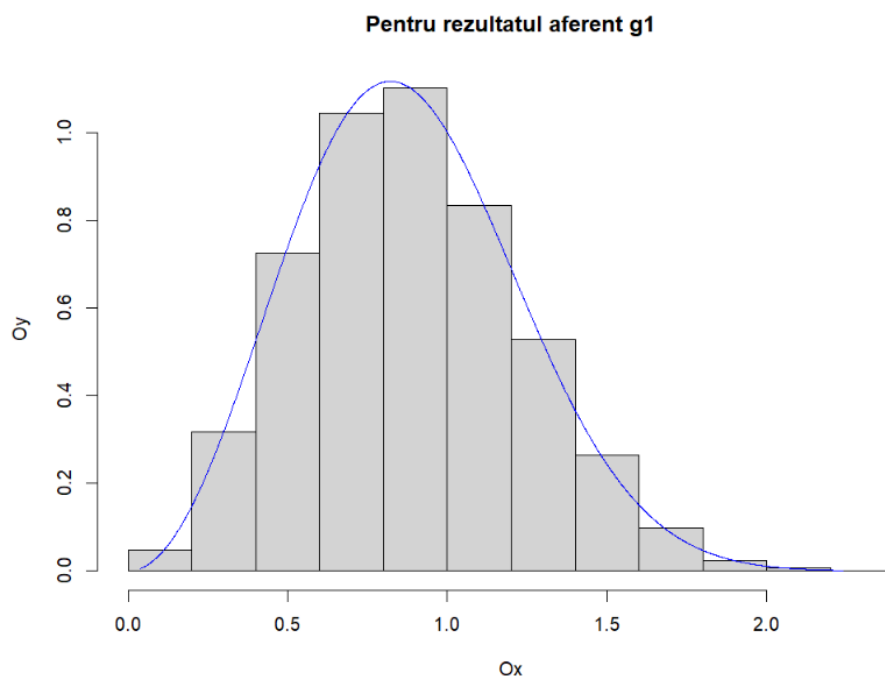
Se observă că funcția fb, în lipsa constantei de normalizare, nu se află deasupra histogramei. Astfel, o metodă de a deduce constanta de normalizare este să găsim o constantă care ar face graficul funcției să se potrivească cu histograma. În cazul nostru, acea constantă este aproximativ 3.844, care pare să fie în jur de  $e\sqrt{2}$ . Înmulțind funcția fb cu  $e\sqrt{2}$ ,



```
f <- function(x) {
  exp(1)*2^0.5*(sin(x))^2*exp(-x^2*sqrt(x))
}

#Găsim ca
hist(X1, freq = F, main='Pentru rezultatul aferent g1', xlab='Ox', ylab='Oy')
lines(x1, f(x1), col = "blue")

hist(X2, freq = F, main='Pentru rezultatul aferent g2', xlab='Ox', ylab='Oy')
lines(x2, f(x2), col = "blue")

hist(X3, freq = F, main='Pentru rezultatul aferent g3', xlab='Ox', ylab='Oy')
lines(x3, f(x3), col = "blue")
```





Astfel, se potrivește bine pentru fiecare g.

### III.

1) Pentru simularea lui  $T$ , vom avea nevoie sa simulam valori din distributiile:

$$\text{Bin}(\alpha_i) \sim \begin{pmatrix} 0 & 1 \\ 1 - \alpha_i & \alpha_i \end{pmatrix} \text{ si } \text{Exp}(\lambda_i)$$

Folosim metoda inversa pentru simularea  $\text{Bin}(\alpha_i)$

- Generam  $U \sim \text{Unif}(0,1)$
- $X = \begin{cases} 0, & \text{daca } u < 1 - \alpha_i \\ 1, & \text{daca } u \geq 1 - \alpha_i \end{cases}$

Folosim metoda inversa pentru simularea  $\text{Exp}(\lambda_i)$

- Generam  $U \sim \text{Unif}(0,1)$
- $F(x) = \begin{cases} 1 - e^{-\lambda_i x}, & x \geq 0 \\ 0, & \text{altfel} \end{cases}$
- $X = F^{-1}(U) \Rightarrow x = F^{-1}(u), \forall x \geq 0$
- $\Rightarrow u = F(x) \Leftrightarrow u = 1 - e^{-\lambda_i x} \Leftrightarrow x = -\frac{1}{\lambda_i} \ln(1 - u)$
- $X = -\frac{1}{\lambda_i} \ln(1 - U)$

$\alpha_i, \lambda_i$  le vom genera uniform

Avand un examen cu un numar de  $n$  exercitii, algoritmul pentru simularea lui  $T$  este:

$T = 0$

pentru  $i \in \overline{1, n}$ :

generam  $b := \text{Bin}(\alpha_i)$

daca  $b = 0$ :

STOP

altfel:

generam  $t := \text{Exp}(\lambda_i)$

$T = T + t$

Algoritmul de mai sus genereaza o singura valoare pentru  $T$ , insa il putem scala in R pentru a genera  $10^6$  valori

```
b <- matrix(Bernoulli(p), nrow = n, ncol = max_n)
t <- matrix(Exponential(1), nrow = n, ncol = max_n)
```



b x					t x				
	V1	V2	V3	V4		V1	V2	V3	V4
1	0	1	0	0	1	11.733883442	14.767293019	89.233004647	3.407201e+01
2	0	0	0	0	2	1.465426997	0.301936768	3.793433059	4.654309e-01
3	1	1	1	0	3	3.780412018	5.936362983	0.279770850	3.286185e+00
4	0	0	0	0	4	3.348444445	1.102455008	0.006555691	8.412302e-03
5	0	1	0	1	5	9.012758122	22.699724217	5.249706733	4.623340e+00

$n \rightarrow$  numarul de sample-uri, i.e.  $10^6$

$\max\_n \rightarrow$  numarul de exercitii, i.e.  $n$

$p \rightarrow$  un vector ce contine valorile  $\alpha_1, \dots, \alpha_n$

$l \rightarrow$  un vector ce contine valorile  $\lambda_1, \dots, \lambda_n$

$b \rightarrow$  o matrice care are pe fiecare coloana cate  $10^6$  sample-uri din  $\text{Bin}(\alpha_i)$ ,  $i \in \overline{1, n}$


$t \rightarrow$  o matrice care are pe fiecare coloana cate  $10^6$  sample-uri din  $\text{Exp}(\lambda_i)$ ,  $i \in \overline{1, n}$

```
stop <- apply(b, MARGIN = 1, function(x) {
  # pastram indicii pozitiilor unde avem 0 in vectorul linie
  i <- which(x == 0)
  # daca nu exista 0, atunci elevul A rezolva tot examenul
  if (length(i) == 0){
    return(max_n)
  }
  # daca exista 0, atunci elevul A se opreste la primul 0
  return(i[1]-1)
})
```

Pentru fiecare sample din  $b$  cautam la al catelea exercitiu se opreste elevul din rezolvat.

```
t_stop <- cbind(t, stop)
# MARGIN=1 -> functia va primia ca input fiecare linie din t_stop
T <- apply(t_stop, MARGIN = 1, function(x){
  # x[length(x)] = indicele de oprire
  # sumam toti timpi pana la indicele de oprire
  return(sum(x[1:x[length(x)]]))
})
```

Pentru fiecare sample din  $t$  facem suma primelor elemente, pana la exercitiul la care elevul se opreste din rezolvat.



```
Expected_value <- mean(T)
```

```
Expected_value 9.14371945041831
```

2) Pentru calculul exact al  $E(T)$  vom considera urmatoarele evenimente

$H$  = evenimentul ca elevul sa termine examenul in timpul  $t$

$B$  = evenimentul ca elevul sa se opreasca din lucru la al  $n$  – lea exercitiu

Vrem sa aflam  $P(H|B) = \frac{P(H \cap B)}{P(B)}$

$X_i \sim \text{Exp}(\lambda_i)$ ,

$$\sum_{i=1}^n X_i \sim \text{Hypo}(\lambda_1, \dots, \lambda_n) \Rightarrow P(H \cap B) = \sum_{i=1}^n \lambda_i e^{-x\lambda_i} \prod_{\substack{j=1 \\ j \neq i}}^n \frac{\lambda_j}{\lambda_j - \lambda_i}$$

$$P(B) = (1 - \alpha_n) \prod_{i=1}^n \alpha_i$$

$$E(T) = \int_{\mathbb{R}} P(H|B) d\lambda, \quad \int_0^{\infty} e^{-x\lambda_i} dx = \frac{1}{\lambda_i}$$

$$E(T) = \frac{\sum_{i=1}^n \prod_{\substack{j=1 \\ j \neq i}}^n \frac{\lambda_j}{\lambda_j - \lambda_i}}{(1 - \alpha_n) \prod_{i=1}^n \alpha_i}$$

$$3) P = \frac{\text{\#cazuri favorabile}}{\text{\#cazuri totale}} = \frac{\text{\#a finalizat activitate}}{10^6}$$

In acest caz, finalizarea activitatii este echivalenta cu a nu se opri la niciun exercitiu.

```
p_finish <- sum(stop == max_n)/n
p_finish | 0.133064
```

$$4) P = \frac{\text{\#cazuri favorabile}}{\text{\#cazuri totale}} = \frac{\text{\#a finalizat activitate intr-un timp mai mic decat } \sigma}{10^6}$$

```
time <- runif(1, 1, 120)
p_finish_time <- sum(T[which(stop == max_n)] < time)/n
p_finish_time | 0.10074
```



5) Vom selecta din T acele valori pentru care a fost finalizata activitatea

```
time_finish <- T[stop == max_n]
min_time <- min(time_finish)
max_time <- max(time_finish)

hypo_samples <- c()
for(i in 1:max_n){
  if(i==1){
    hypo_samples <- rexp(length(time_finish), l[i])
  } else{
    hypo_samples <- hypo_samples+rexp(length((time_finish)), l[i])
  }
}
max_time <- max(hypo_samples)

# plotam histogramele una sub cealalta
par(mfrow=c(2,1))
hist(time_finish, xlim = c(min_time, max_time), breaks = 10^4, freq = FALSE)
hist(hypo_samples, xlim = c(min_time, max_time), breaks = 10^4, freq = FALSE)
```

Mai departe am generat o distributie hypoexponentiala cu aceasi parametri si acelasi numar de sample-uri.



Observatie:

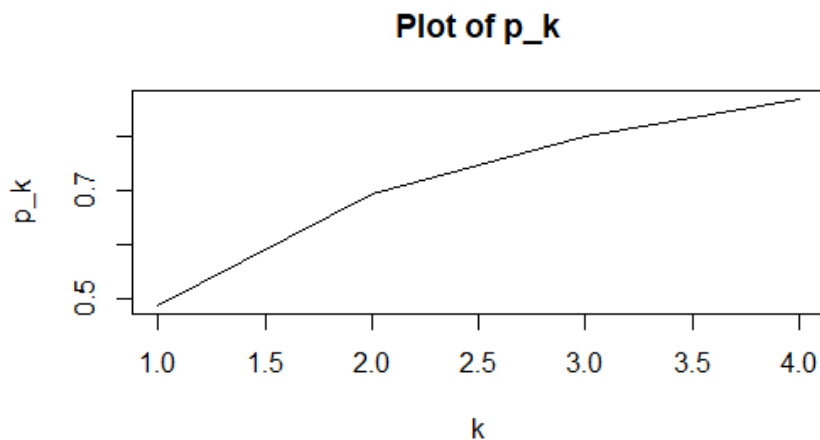
Finalizarea activitatii presupune rezolvarea tuturor exercitiilor, astfel ca pentru calculul lui T va trebui sa sumam toate variabilele aleatoare din distributiile exponentiale de parametri  $\lambda_i$ , acest lucru nu este nimic altceva decat distributia  $Hypo(\lambda_1, \dots, \lambda_n)$

6)  $P_k = \frac{\text{\#cazuri favorabile}}{\text{\#cazuri totale}} = \frac{\text{\#s-a oprit din lucru pana la exc k}}{10^6}$

```

p_k <- c()
for(k in 1:max_n){
  p_k <- c(p_k, sum(stop < k)/n)
}
plot(1:max_n, p_k, type="l", xlab="k", ylab="p_k", main="Plot of p_k")
p_k
| num [1:4] 0.49 0.692 0.8 0.867

```



#### Exercitiul 4:


1) Fie  $X_1, X_2, \dots, X_n$  v.a. i.i.d  $X_i \sim \text{Beta}(1, 1)$  și  $X \sim \text{Binomial}(1, 1/2)$ .

(i) Verificați dacă  $X_n \rightarrow X$ .


```
# Generam sirul Xn
genXn <- function(n)
{
  res <- rbeta(n, 1/n, 1/n)
  return(res)
}
# Folosim functia check.convergence in modul "L" pentru a verifica convergenta in distributie la
# X pe care il introducem prin functia de masa si prin cea de repartitie
```

```
check.convergence(500, 250, genXn, mode="L",
  density = F,
  densfunc = function(x){dbinom(x, 1, 1/2)},
  probfunc = function(x){pbinom(x, 1, 1/2)})
```

```
check.convergence(2000, 1000, genXn, mode="L",
  density = F,
  densfunc = function(x){dbinom(x, 1, 1/2)},
  probfunc = function(x){pbinom(x, 1, 1/2)})
```



Acesta este graficul pentru  $n_{\max} = 500$  și  $M = 250$ .



Acesta este graficul obtinut pentru  $n_{\max} = 2000$  si  $M = 1000$ .

Putem observa ca de la un grafic la altul eroarea a scazut semnificativ, deci pentru un  $n_{\max}$  suficient de mare si un  $M$  suficient de mare am obtine graficul erorii foarte aproape de planul orizontal zero.

Prin urmare putem trage concluzia ca  $X_n$  converge in distributie la  $X$ .

(ii) Dar în cazul în care  $X_i \sim \text{Beta}(\frac{a}{n}, \frac{b}{n})$ , cu  $a > 0, b > 0$ ?

# Generam sirul de variabile aleatoare, de aceasta data ca o functie de n, a si b

```
genXn <- function(n, a, b)
```

```
{
```

```
  res <- rbeta(n, a/n, b/n)
```

```
  return(res)
```

```
}
```

# Aici trebuie sa completam cu argumentul argsXn unde adaugam a si b carora le dam niste valori default

```
check.convergence(500, 250, genXn, argsXn=list(a = 5, b = 5), mode="L",
```

```
  density = F,
```

```
  densfunc = function(x){dbinom(x, 1, 1/2)},
```

```
  probfunc = function(x){pbinom(x, 1, 1/2)})
```

```
check.convergence(2000, 1000, genXn, argsXn=list(a = 5, b = 5), mode="L",
```

```
  density = F,
```



```
  densfunc = function(x){dbinom(x, 1, 1/2)},
```

```
probfunc = function(x){pbinom(x, 1, 1/2)}
```

```
check.convergence(500, 250, genXn, argsXn=list(a = 2, b = 5), mode="L",
  density = F,
  densfunc = function(x){dbinom(x, 1, 1/2)},
  probfunc = function(x){pbinom(x, 1, 1/2)})
check.convergence(2000, 1000, genXn, argsXn=list(a = 2, b = 5), mode="L",
  density = F,
  densfunc = function(x){dbinom(x, 1, 1/2)},
  probfunc = function(x){pbinom(x, 1, 1/2)})
```

```
check.convergence(500, 250, genXn, argsXn=list(a = 5, b = 2), mode="L",
  density = F,
  densfunc = function(x){dbinom(x, 1, 1/2)},
  probfunc = function(x){pbinom(x, 1, 1/2)})
check.convergence(2000, 1000, genXn, argsXn=list(a = 5, b = 2), mode="L",
  density = F,
  densfunc = function(x){dbinom(x, 1, 1/2)},
  probfunc = function(x){pbinom(x, 1, 1/2)})
```


### Convergence in law?




Pentru a si b egale ( $a = b = 5$ ) obtinem ceva analog cu punctul (i). In stanga avem graficul pentru  $n_{\max} = 500$  si  $M = 250$ , iar in dreapta graficul pentru  $n_{\max} = 2000$  si  $M = 1000$ . In acest caz  $X_n$  converge in distributie la  $X$ .



Convergence in law?




Convergence in law?




Pentru  $a = 2$  si  $b = 5$ , eroarea ramane constanta, pentru (500, 250) si (2000, 1000) de unde tragem concluzia ca pentru  $a < b$  si  $X_i \sim \text{Beta}(a/b, b/b)$ , cu  $a > 0, b > 0$ ,  $X_n$  nu converge in distributie la  $X \sim \text{Binomial}(1, 1/2)$ .

Convergence in law?



Convergence in law?



Pentru  $a = 5$  si  $b = 2$ , obtinem acelasi lucru ca pentru  $a = 2$  si  $b = 5$  si anume ca pentru  $a > b$  si  $X_i \sim \text{Beta}(a/b, b/b)$ , cu  $a > 0, b > 0$ ,  $X_n$  nu converge in distributie la  $X \sim \text{Binomial}(1, 1/2)$ .


2) Fie  $X_1, X_2, \dots, X_n$  v.a. i.i.d uniform distribuite pe mulțimea de valori  $\{1/n, 2/n, \dots, 1\}$  și  $X \sim \text{Unif}(0,1)$ . (i) Verificați dacă  $X_n \xrightarrow{d} X$ .

```
# Functia care ne genereaza valori cu aceeasi probabilitate
rUnifDisc <- function(n, discreteUnifValues) sample(discreteUnifValues, n, replace=T)
# Generam Xn pe care il vom folosi in check.convergence, uniform discret pe {1/n, 2/n, ..., 1}
genXn <- function(n)
{
  discreteUnifValues <- seq(from = 1/n, to = 1, by = 1/n)
  res <- rUnifDisc(n, discreteUnifValues)
  return(res)
}
# Verificam convergenta in distributie la X uniform continua pe (0, 1)
```


```
check.convergence(nmax = 500, M = 250, genXn, mode="L",
  density = F,
  densfunc = function(x){dunif(x, 0, 1)},
  probfunc = function(x){punif(x, 0, 1)})
```

```
check.convergence(nmax = 2000, M = 1000, genXn, mode="L",
  density = F,
  densfunc = function(x){dunif(x, 0, 1)},
  probfunc = function(x){punif(x, 0, 1)})
```

Convergence in law?




Convergence in law?



In graficul din stanga, am verificat convergenta pentru  $n_{\max} = 500$  si  $M = 250$ , iar in graficul din dreapta pentru  $n_{\max} = 2000$  si  $M = 1000$ . Observam ca diferenta dintre  $F_n(t)$  si  $F(t)$  a scazut odata cu cresterea lui  $n$  si  $M$ , asadar  $X_n$  converge in distributie la  $X \sim \text{Unif}(0,1)$ .

(ii) Dar  $X_n \xrightarrow{p} X$ ?

```
# Functia care ne genereaza valori cu aceeasi probabilitate pe intervalul discretizat anterior
rUnifDisc <- function(n, discreteUnifValues) sample(discreteUnifValues, n, replace=T)
# Generam un nou sir Xn, care este obtinut din Xn generat ca in subpunctul 2i)
# din care scadem un X cu distributie uniforma pe (0, 1)
genXn <- function(n)
{ X <- runif(1)
  discreteUnifValues <- seq(from = 1/n, to = 1, by = 1/n)
  res <- rUnifDisc(n, discreteUnifValues) - X
  return(res)
}
check.convergence(nmax = 2000, M = 1000, genXn, mode="p")
```



A avea convergenta in probabilitate de la  $X_n$  la  $X$  este echivalent cu a avea convergenta in probabilitate de la  $X_n - X$  la 0. Prin urmare generatorul nostru este sub forma  $X_n - X$ , iar pentru a avea convergenta in probabilitate ar trebui sa observam in graficul din dreapta o descrestere spre 0 a lui  $p_n$ . Pentru ca  $p_n$  nu scade spre 0 putem concluda ca  $X_n$  nu converge in probabilitate la  $X$ .


(i) Verificați că  $\min\{X_1, X_2, \dots, X_n\} \square. \square. \rightarrow m$

```
genXn <- function(n)
```

```
{
  xMin <- cummin(rexp(n, 2))
# Aleg ca infimum minimul repartitiei xMin obtinute
  infimum <- min(xMin)
# Verific daca xMin converge aproape sigur la infimum
  return(xMin - infimum)
}
```

```
genXn <- function(n)
{
  xMin <- cummin(rpois(n, 5))
  infimum <- min(xMin)
  return(xMin - infimum)
}
```


26



Observam ca pentru  $n_{\max} = 2000$  si  $M = 1000$ , in graficul din dreapta, an descreste spre 0, deci putem concluziona ca  $\min\{X_1, X_2 \dots X_n\} \square. \square. \rightarrow m$ , pentru  $X_i \sim \text{Pois}(5)$ .

(ii) Verificati cã  $\max\{X_1, X_2 \dots X_n\} \square. \square. \rightarrow M$ .

```
# Luam Xn exponentiale de 2,
genXn <- function(n)
{ # xMax va fi max{X1,X2,...Xn}
  xMax <- cummax(rexp(n, 2))
  # supremum luam valoarea maxima din xMax
  supremum <- max(xMax)
  # verificam convergenta aproape sigura a lui xMax la supremum
  return(xMax - supremum)
}
check.convergence(nmax = 2000, M = 1000, genXn, mode = "as")
```

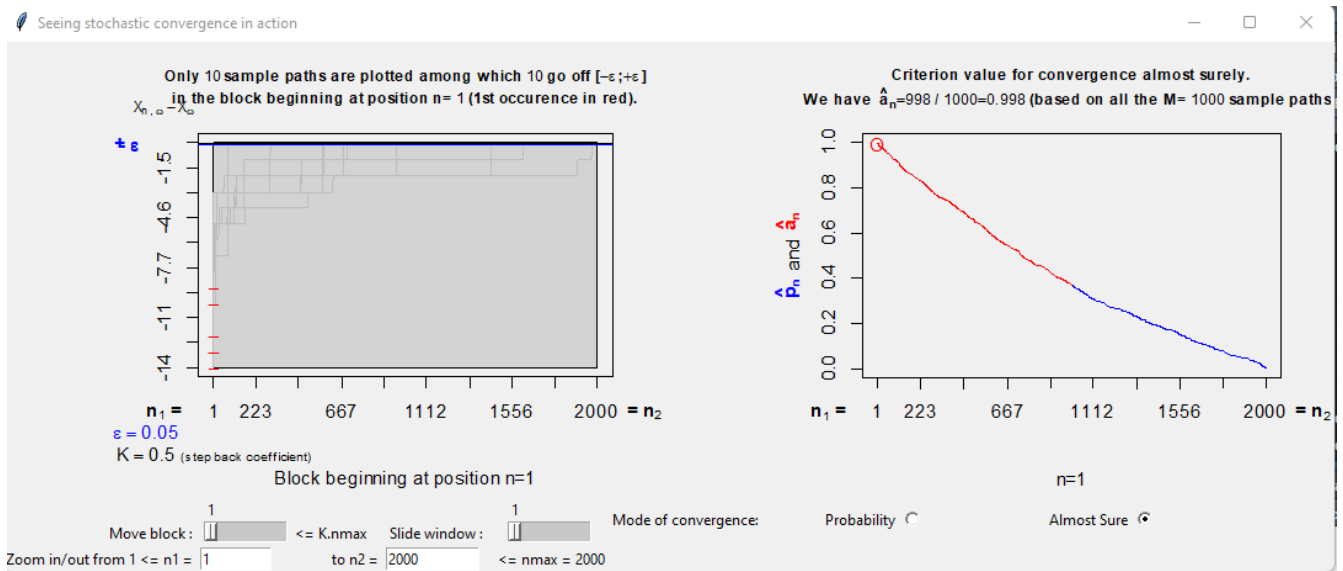


Observam ca pentru  $n_{\max} = 2000$  si  $M = 1000$ , in graficul din dreapta, an descreste spre 0, deci putem

concluziona ca  $\max\{X_1, X_2 \dots X_n\} \square. \square. \rightarrow M(\text{supremumul, nu argumentul din check.convergence})$ , pentru  $X_i \sim \text{Exp}(2)$ .

#Verificam si pentru  $X_i \sim \text{Pois}(5)$ .

```
genXn <- function(n)
{
  xMax <- cummax(rpois(n, 5))
  supremum <- max(xMax)
  return(xMax - supremum)
}
check.convergence(nmax = 2000, M = 1000, genXn, mode = "as")
```



Observam ca pentru  $n_{\max} = 2000$  si  $M = 1000$ , in graficul din dreapta, an descreste spre 0, deci putem concluziona ca  $\max\{X_1, X_2 \dots X_n\} \square. \square. \rightarrow M(\text{supremumul, nu argumentul din check.convergence})$ , pentru  $X_i \sim \text{Pois}(5)$ .